EXAMEN FINAL

Ejercicio 1:

Aviación Civil

La Administración Nacional de Aviación Civil necesita una serie de informes para elevar al ministerio de transporte acerca de los aterrizajes y despegues en todo el territorio Argentino, como puede ser: cuales aviones son los que más volaron, cuántos pasajeros volaron, ciudades de partidas y aterrizajes entre fechas determinadas, etc.
Usted como data engineer deberá realizar un pipeline con esta información, automatizarlo y realizar los análisis de datos solicitados que permita responder las preguntas de negocio, y hacer sus recomendaciones con respecto al estado actual.

Listado de vuelos realizados:
https://datos.gob.ar/lv/dataset/transporte-aterrizajes-despegues-procesados-por-administracion-nacional-aviacion-civil-anac

Listado de detalles de aeropuertos de Argentina:
https://datos.transporte.gob.ar/dataset/lista-aeropuertos

TAREAS

1. Hacer ingest de los siguientes files relacionados con transporte aéreo de Argentina :

2021: https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv

2022: https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv

Aeropuertos_detalles:
https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv

Comenzaré realizando el **ingest** con el script **ingest_ejercicio_1.sh**, alojado en **/home/hadoop/scripts**. Este script permite descargar los archivos al directorio **/home/hadoop/landing** y posteriormente ingestarlos en **hdfs** en el directorio **/ingest**.

```
################################################################################

# Archivo: ingest_ejercicio_1.sh
#
# Descarga e Ingest en HDFS de los archivos:
# https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv
# https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv
# https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv
################################################################################
```

Punto 1

Descarga datos desde el repositorio al directorio /home/hadoop/landing
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv

Lleva el archivo a HDFS al directorio /ingest
hdfs dfs -put /home/hadoop/landing/2021-informe-ministerio.csv /ingest
hdfs dfs -put /home/hadoop/landing/202206-informe-ministerio.csv /ingest
hdfs dfs -put /home/hadoop/landing/aeropuertos_detalle.csv /ingest

Borra el archivo starwars.csv del directorio /home/hadoop/landing/
rm /home/hadoop/landing/2021-informe-ministerio.csv
rm /home/hadoop/landing/202206-informe-ministerio.csv
rm /home/hadoop/landing/aeropuertos_detalle.csv

Vista desde el **bash**:

```
/home/crbdata/.hushlogin file.
crbdata@RubenBageta:/mnt/c/Users/Carlos Rubén Bageta$ docker exec -it edvai_hadoop bash
root@615cf53bef6c:/# su hadoop
hadoop@615cf53bef6c:/$ cd /home/hadoop/scripts
hadoop@615cf53bef6c:~/scripts$ ls
Notebook          landing_3.sh                start-services.sh    transform_load_5.py
QueryResult.java  pyspark_jupyter.sh          tl6_run.log          transform_load_6.py
derby.log         query_db_2_hdfs_parquet.sh  transform_load.py    transformation.py
ingest.sh         query_db_2_hdfs_parquet_2.sh  transform_load_2.py  weather_str_transform.py
landing.sh        query_db_2_hdfs_parquet_3.sh  transform_load_3.py  yahoo_weather2kafka.py
landing_2.sh      spark-warehouse             transform_load_4.py
hadoop@615cf53bef6c:~/scripts$ cat > ingest_ejercicio_1.sh
################################################################################
# Archivo: ingest_ejercicio_1.sh
#
# Descarga e Ingest en HDFS de los archivos:
# https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv
# https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv
# https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv
################################################################################

# Punto 1

# Descarga datos desde el repositorio al directorio /home/hadoop/landing
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv
wget -P /home/hadoop/landing https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv


# Lleva el archivo a HDFS al directorio /ingest
hdfs dfs -put /home/hadoop/landing/2021-informe-ministerio.csv /ingest
hdfs dfs -put /home/hadoop/landing/202206-informe-ministerio.csv /ingest
hdfs dfs -put /home/hadoop/landing/aeropuertos_detalle.csv /ingest


# Borra el archivo starwars.csv del directorio /home/hadoop/landing/
rm /home/hadoop/landing/2021-informe-ministerio.csv
rm /home/hadoop/landing/202206-informe-ministerio.csv
rm /home/hadoop/landing/aeropuertos_detalle.csv
hadoop@615cf53bef6c:~/scripts$
```

A continuación, le asignamos permisos al citado archivo:

```
hadoop@615cf53bef6c:~/scripts$ chmod 777 ingest_ejercicio_1.sh
hadoop@615cf53bef6c:~/scripts$ ls -l
total 144
drwxrwxr-x 3 hadoop hadoop  4096 Sep 29 19:46 Notebook
-rw-rw-r-- 1 hadoop hadoop 14298 Nov  1 15:16 QueryResult.java
-rw-rw-r-- 1 hadoop hadoop   670 Feb 28  2022 derby.log
-rwxrwxr-x 1 hadoop hadoop   272 Sep 22 01:14 ingest.sh
-rwxrwxrwx 1 hadoop hadoop  1393 Nov 15 19:31 ingest_ejercicio_1.sh
-r-xr-xr-x 1 hadoop hadoop   398 Sep 17 16:57 landing.sh
-rwxrwxrwx 1 hadoop hadoop   716 Oct 18 16:24 landing_2.sh
-rwxrwxrwx 1 hadoop hadoop   914 Oct 24 19:25 landing_3.sh
-rwxrwxrwx 1 hadoop hadoop   273 Sep 28 12:14 pyspark_jupyter.sh
-rwxrwxrwx 1 hadoop hadoop   668 Nov  1 15:12 query_db_2_hdfs_parquet.sh
-rwxrwxrwx 1 hadoop hadoop   549 Nov  1 16:00 query_db_2_hdfs_parquet_2.sh
-rwxrwxrwx 1 hadoop hadoop   486 Nov  1 16:31 query_db_2_hdfs_parquet_3.sh
drwxr-xr-x 2 hadoop hadoop  4096 Feb  9  2022 spark-warehouse
-rwxrwxrwx 1 hadoop hadoop  1089 May  9  2022 start-services.sh
-rw-rw-r-- 1 hadoop hadoop 37302 Nov  7 13:41 tl6_run.log
-rwxrwxrwx 1 hadoop hadoop  1964 Oct 19 00:37 transform_load.py
-rwxrwxrwx 1 hadoop hadoop  2897 Oct 19 12:48 transform_load_2.py
-rwxrwxrwx 1 hadoop hadoop  3909 Oct 25 04:35 transform_load_3.py
-rwxrwxrwx 1 hadoop hadoop  1734 Nov  2 23:50 transform_load_4.py
-rwxrwxrwx 1 hadoop hadoop  2619 Nov  3 00:07 transform_load_5.py
-rwxrwxrwx 1 hadoop hadoop  2713 Nov  7 16:27 transform_load_6.py
-rwxrwxrwx 1 hadoop hadoop  1058 May  9  2022 transformation.py
-rwxrwxrwx 1 hadoop hadoop  2068 Oct 31 22:14 weather_str_transform.py
-rwxrwxrwx 1 hadoop hadoop  1747 Nov  1 01:13 yahoo_weather2kafka.py
hadoop@615cf53bef6c:~/scripts$
```

Revisamos que el archivo realiza el **ingest** correctamente:

```
hadoop@615cf53bef6c:~/scripts$ ./ingest_ejercicio_1.sh
--2025-11-15 19:36:28--  https://data-engineer-edvai-public.s3.amazonaws.com/2021-informe-ministerio.csv
Resolving data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)... 16.15.191.116, 3.5.16.172, 3.5.22.216, ...
Connecting to data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)|16.15.191.116|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 32322556 (31M) [text/csv]
Saving to: '/home/hadoop/landing/2021-informe-ministerio.csv'

2021-informe-ministerio.csv           100%[=====================================================================>]  30.82M   157KB/s    in 7m 48s

2025-11-15 19:44:17 (67.5 KB/s) - '/home/hadoop/landing/2021-informe-ministerio.csv' saved [32322556/32322556]

--2025-11-15 19:44:17--  https://data-engineer-edvai-public.s3.amazonaws.com/202206-informe-ministerio.csv
Resolving data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)... 52.217.228.161, 16.15.185.170, 3.5.22.9, ...
Connecting to data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)|52.217.228.161|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 22833520 (22M) [text/csv]
Saving to: '/home/hadoop/landing/202206-informe-ministerio.csv'

202206-informe-ministerio.csv         100%[=====================================================================>]  21.78M   206KB/s    in 2m 52s

2025-11-15 19:47:09 (130 KB/s) - '/home/hadoop/landing/202206-informe-ministerio.csv' saved [22833520/22833520]

--2025-11-15 19:47:09--  https://data-engineer-edvai-public.s3.amazonaws.com/aeropuertos_detalle.csv
Resolving data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)... 52.216.251.60, 16.15.191.135, 52.217.137.177, ...
Connecting to data-engineer-edvai-public.s3.amazonaws.com (data-engineer-edvai-public.s3.amazonaws.com)|52.216.251.60|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 136007 (133K) [text/csv]
Saving to: '/home/hadoop/landing/aeropuertos_detalle.csv'

aeropuertos_detalle.csv               100%[=====================================================================>] 132.82K   158KB/s    in 0.8s

2025-11-15 19:47:11 (158 KB/s) - '/home/hadoop/landing/aeropuertos_detalle.csv' saved [136007/136007]

hadoop@615cf53bef6c:~/scripts$ hdfs dfs -ls /ingest
Found 7 items
-rw-r--r--   1 hadoop supergroup   32322556 2025-11-15 19:47 /ingest/2021-informe-ministerio.csv
-rw-r--r--   1 hadoop supergroup   22833520 2025-11-15 19:47 /ingest/202206-informe-ministerio.csv
-rw-r--r--   1 hadoop supergroup     136007 2025-11-15 19:47 /ingest/aeropuertos_detalle.csv
-rw-r--r--   1 hadoop supergroup      17478 2025-10-25 04:05 /ingest/constructors.csv
-rw-r--r--   1 hadoop supergroup      94367 2025-10-25 04:05 /ingest/drivers.csv
-rw-r--r--   1 hadoop supergroup     164344 2025-10-25 04:05 /ingest/races.csv
-rw-r--r--   1 hadoop supergroup    1721961 2025-10-25 04:05 /ingest/results.csv
hadoop@615cf53bef6c:~/scripts$
```

Se observa que los archivos fueron ingestados correctamente en **hdfs**

2. Crear 2 tablas en el datawarehouse, una para los vuelos realizados en 2021 y 2022 (2021-informe-ministerio.csv y 202206-informe-ministerio) y otra tabla para el detalle de los aeropuertos (aeropuertos_detalle.csv)

En primer lugar, creamos la base de datos **aeropuertos** en **Hive**:

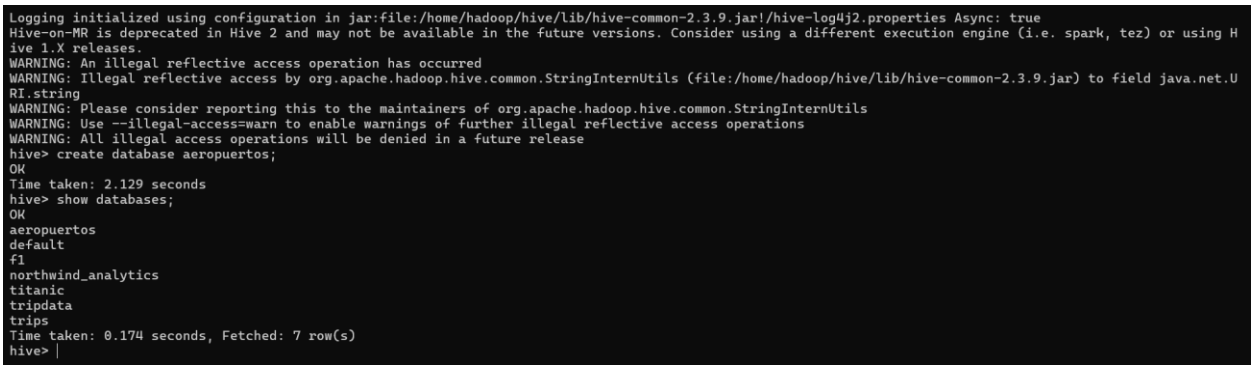

Posteriormente, creamos las tablas requeridas (parquet) en la base de datos:

```
-- TABLA 1: VUELOS (Parquet)

DROP TABLE IF EXISTS aeropuertos.aeropuerto_tabla;

CREATE EXTERNAL TABLE aeropuertos.aeropuerto_tabla (
  fecha                 DATE,
  horaUTC               STRING,
  clase_de_vuelo        STRING,
  clasificacion_de_vuelo STRING,
  tipo_de_movimiento    STRING,
  aeropuerto            STRING,
  origen_destino        STRING,
  aerolinea_nombre      STRING,
  aeronave              STRING,
  pasajeros             INT
)
STORED AS PARQUET
LOCATION '/tables/external/aeropuertos/aeropuerto_tabla';


-- TABLA 2: AEROPUERTOS (Parquet)

DROP TABLE IF EXISTS aeropuertos.aeropuerto_detalles_tabla

CREATE EXTERNAL TABLE aeropuertos.aeropuerto_detalles_tabla (
  aeropuerto            STRING,
  oac                   STRING,
  iata                  STRING,
  tipo                  STRING,
  denominacion          STRING,
  coordenadas           STRING,
  latitud               STRING,
  longitud              STRING,
```

```
  elev                  FLOAT,
  uom_elev              STRING,
  ref                   STRING,
  distancia_ref         FLOAT,
  direccion_ref         STRING,
  condicion             STRING,
  control               STRING,
  region                STRING,
  uso                   STRING,
  trafico               STRING,
  sna                   STRING,
  concesionado          STRING,
  provincia             STRING
)
STORED AS PARQUET
LOCATION '/tables/external/aeropuertos/aeropuerto_detalles_tabla';
```

Vista desde el **bash**:

```
hive> -- TABLA 1: VUELOS (Parquet)
hive>
    > DROP TABLE IF EXISTS aeropuertos.aeropuerto_tabla;
OK
Time taken: 0.037 seconds
hive> CREATE EXTERNAL TABLE aeropuertos.aeropuerto_tabla (
    >     fecha DATE,
    >     horaUTC STRING,
    >     clase_de_vuelo STRING,
    >     clasificacion_de_vuelo STRING,
    >     tipo_de_movimiento STRING,
    >     aeropuerto STRING,
    >     origen_destino STRING,
    >     aerolinea_nombre STRING,
    >     aeronave STRING,
    >     pasajeros INT
    > )
    > STORED AS PARQUET
    > LOCATION '/tables/external/aeropuertos/aeropuerto_tabla';
OK
Time taken: 0.546 seconds
hive>
```

```
hive> DROP TABLE IF EXISTS aeropuertos.aeropuerto_detalles_tabla;
OK
Time taken: 0.032 seconds
hive> CREATE EXTERNAL TABLE aeropuertos.aeropuerto_detalles_tabla (
    >     aeropuerto STRING,
    >     oac STRING,
    >     iata STRING,
    >     tipo STRING,
    >     denominacion STRING,
    >     coordenadas STRING,
    >     latitud STRING,
    >     longitud STRING,
    >     elev FLOAT,
    >     uom_elev STRING,
    >     ref STRING,
    >     distancia_ref FLOAT,
    >     direccion_ref STRING,
    >     condicion STRING,
    >     control STRING,
    >     region STRING,
    >     uso STRING,
    >     trafico STRING,
    >     sna STRING,
    >     concesionado STRING,
    >     provincia STRING
    > )
    > STORED AS PARQUET
    > LOCATION '/tables/external/aeropuertos/aeropuerto_detalles_tabla';
OK
Time taken: 0.174 seconds
hive>
```

Visualizamos que las tablas se crearon correctamente:

```
hive> describe formatted aeropuertos.aeropuerto_tabla
    > ;
OK
# col_name              data_type               comment

fecha                   date
horautc                 string
clase_de_vuelo          string
clasificacion_de_vuelo  string
tipo_de_movimiento      string
aeropuerto              string
origen_destino          string
aerolinea_nombre        string
aeronave                string
pasajeros               int

# Detailed Table Information
Database:               aeropuertos
Owner:                  hadoop
CreateTime:             Sat Nov 15 21:09:07 ART 2025
LastAccessTime:         UNKNOWN
Retention:              0
Location:               hdfs://172.17.0.2:9000/tables/external/aeropuertos/aeropuerto_tabla
Table Type:             EXTERNAL_TABLE
Table Parameters:
        EXTERNAL                TRUE
        transient_lastDdlTime   1763251747

# Storage Information
SerDe Library:          org.apache.hadoop.hive.ql.io.parquet.serde.ParquetHiveSerDe
InputFormat:            org.apache.hadoop.hive.ql.io.parquet.MapredParquetInputFormat
OutputFormat:           org.apache.hadoop.hive.ql.io.parquet.MapredParquetOutputFormat
Compressed:             No
Num Buckets:            -1
Bucket Columns:         []
Sort Columns:           []
Storage Desc Params:
        serialization.format    1
Time taken: 0.192 seconds, Fetched: 35 row(s)
hive>
```

```
hive> describe formatted aeropuertos.aeropuerto_detalles_tabla
    > ;
OK
# col_name              data_type               comment

aeropuerto              string
oac                     string
iata                    string
tipo                    string
denominacion            string
coordenadas             string
latitud                 string
longitud                string
elev                    float
uom_elev                string
ref                     string
distancia_ref           float
direccion_ref           string
condicion               string
control                 string
region                  string
uso                     string
trafico                 string
sna                     string
concesionado            string
provincia               string

# Detailed Table Information
Database:               aeropuertos
Owner:                  hadoop
CreateTime:             Sat Nov 15 21:12:12 ART 2025
LastAccessTime:         UNKNOWN
Retention:              0
Location:               hdfs://172.17.0.2:9000/tables/external/aeropuertos/aeropuerto_detalles_tabla
Table Type:             EXTERNAL_TABLE
Table Parameters:
        EXTERNAL                TRUE
        transient_lastDdlTime   1763251932

# Storage Information
SerDe Library:          org.apache.hadoop.hive.ql.io.parquet.serde.ParquetHiveSerDe
InputFormat:            org.apache.hadoop.hive.ql.io.parquet.MapredParquetInputFormat
OutputFormat:           org.apache.hadoop.hive.ql.io.parquet.MapredParquetOutputFormat
Compressed:             No
Num Buckets:            -1
Bucket Columns:         []
Sort Columns:           []
Storage Desc Params:
        serialization.format    1
Time taken: 0.096 seconds, Fetched: 46 row(s)
hive>
```

```
hive> use aeropuertos
    > ;
OK
Time taken: 0.054 seconds
hive> show tables;
OK
aeropuerto_detalles_tabla
aeropuerto_tabla
Time taken: 0.066 seconds, Fetched: 2 row(s)
hive>
```

3. Realizar un proceso automático orquestado por airflow que ingeste los archivos previamente mencionados entre las fechas 01/01/2021 y 30/06/2022 en las dos columnas creadas.

   Los archivos 202206-informe-ministerio.csv y 202206-informe-ministerio.csv → en la tabla aeropuerto_tabla

   El archivo aeropuertos_detalle.csv → en la tabla aeropuerto_detalles_tabla

4. Realizar las siguiente transformaciones en los pipelines de datos:
   - Eliminar la columna inhab ya que no se utilizará para el análisis
   - Eliminar la columna fir ya que no se utilizará para el análisis
   - Eliminar la columna “calidad del dato” ya que no se utilizará para el análisis
   - Filtrar los vuelos internacionales ya que solamente se analizarán los vuelos domésticos
   - En el campo pasajeros si se encuentran campos en Null convertirlos en 0 (cero)
   - En el campo distancia_ref si se encuentran campos en Null convertirlos en 0 (cero)

5. Mostrar mediante una impresión de pantalla, que los tipos de campos de las tablas sean los solicitados en el datawarehouse (ej: fecha date, aeronave string, pasajeros integer, etc.)

Realizaremos **primero el punto 4**, dado que así podemos hacer las transformaciones con **pyspark** en forma distribuida. EL script **transform_load_7.py**, alojado en **/home/hadoop/scripts** realiza las transformaciones pedidas.

```python
#########################################################################################################################
# Archivo: transform_load_7.py
#########################################################################################################################

# Importamos librerias
from pyspark.sql import SparkSession
from pyspark.sql import functions as F


def main():
    # --- Parámetros de HDFS ---
    NN_URI = "hdfs://172.17.0.2:9000"  # ajusta si tu NameNode/puerto son otros
    INPUT_INFORME_1   = f"{NN_URI}/ingest/2021-informe-ministerio.csv"
    INPUT_INFORME_2   = f"{NN_URI}/ingest/202206-informe-ministerio.csv"
    INPUT_DETALLE_AEROPUERTOS = f"{NN_URI}/ingest/aeropuertos_detalle.csv"
    OUTPUT_TABLA_1_DW = f"{NN_URI}/tables/external/aeropuertos/aeropuerto_tabla"
    OUTPUT_TABLA_2_DW = f"{NN_URI}/tables/external/aeropuertos/aeropuerto_detalles_tabla"

    # 1) Crear la sesión de Spark con soporte Hive y FS por defecto en HDFS
    spark = (
        SparkSession
            .builder
            .appName("transform_load_7")
            .enableHiveSupport()
            .config("spark.hadoop.fs.defaultFS", NN_URI)
            .config("spark.sql.warehouse.dir", OUTPUT_TABLA_1_DW)
            .config("spark.sql.warehouse.dir", OUTPUT_TABLA_2_DW)
            .getOrCreate()
    )

    # 2) Rutas de entrada (csv desde HDFS)
    df = spark.read.csv(INPUT_INFORME_1, header=True, inferSchema=True, sep=";")
    df1 = spark.read.csv(INPUT_INFORME_2, header=True, inferSchema=True, sep=";")
    df2 = spark.read.csv(INPUT_DETALLE_AEROPUERTOS, header=True, inferSchema=True, sep=";")


    # 3) Transformaciones (casteo de tipos)

    # Casteo de df y df1 (ademas eliminamos la columna 'Calidad dato' que no es necesaria)

    def castear_vuelos(df): # Funcion para castear los dataframes de vuelos (sin 'Calidad dato')
        return df.select(
            F.to_date(F.col("Fecha"), "dd/MM/yyyy").alias("fecha"),
            F.col("Hora UTC").cast("string").alias("horaUTC"),
            F.col("Clase de Vuelo (todos los vuelos)").cast("string").alias("clase_de_vuelo"),
            F.col("Clasificación Vuelo").cast("string").alias("clasificacion_de_vuelo"),
            F.col("Tipo de Movimiento").cast("string").alias("tipo_de_movimiento"),
            F.col("Aeropuerto").cast("string").alias("aeropuerto"),
            F.col("Origen / Destino").cast("string").alias("origen_destino"),
            F.col("Aerolinea Nombre").cast("string").alias("aerolinea_nombre"),
            F.col("Aeronave").cast("string").alias("aeronave"),
            F.col("Pasajeros").cast("int").alias("pasajeros")
        )

```

```
    # Usamos la función para castear ambos dataframes

    df_cast = castear_vuelos(df)
    df1_cast = castear_vuelos(df1)

    # Unimos ambos dataframes casteados

    df_union = df_cast.unionByName(df1_cast)

    # Filtramos los vuelos domésticos

    df_domestico = df_union.filter(
        F.lower(F.col("clasificacion_de_vuelo")) == "domestico"
    )

    #  Rellenamos los valores nulos en la columna 'pasajeros' con 0

    df_load = df_domestico.fillna({"pasajeros": 0})

    # Casteo de df2 (aeropuertos detalle) No figura la columna 'inhab' ni 'fir' en la tabla destino, por lo que no se incluyen

    df2_cast = df2.select(
        # local -> aeropuerto
        F.col("local").cast("string").alias("aeropuerto"),
        F.col("oaci").cast("string").alias("oac"),
        F.col("iata").cast("string").alias("iata"),
        F.col("tipo").cast("string").alias("tipo"),
        F.col("denominacion").cast("string").alias("denominacion"),
        F.col("coordenadas").cast("string").alias("coordenadas"),
        F.col("latitud").cast("string").alias("latitud"),
        F.col("longitud").cast("string").alias("longitud"),
        F.col("elev").cast("float").alias("elev"),
        F.col("uom_elev").cast("string").alias("uom_elev"),
        F.col("ref").cast("string").alias("ref"),
        F.col("distancia_ref").cast("float").alias("distancia_ref"),
        F.col("direccion_ref").cast("string").alias("direccion_ref"),
        F.col("condicion").cast("string").alias("condicion"),
        F.col("control").cast("string").alias("control"),
        F.col("region").cast("string").alias("region"),
        F.col("uso").cast("string").alias("uso"),
        F.col("trafico").cast("string").alias("trafico"),
        F.col("sna").cast("string").alias("sna"),
        F.col("concesionado").cast("string").alias("concesionado"),
        F.col("provincia").cast("string").alias("provincia"),

    )

    #  Rellenamos los valores nulos en la columna 'distancia_ref' con 0

    df2_load = df2_cast.fillna({"distancia_ref": 0})


    # (opcional) métricas rápidas al log
    print(f"[INFO] filas vuelos        : {df_load.count()}")
    print(f"[INFO] filas aeropuertos detalles : {df2_load.count()}")

    # 5) Load (Parquet a HDFS)
    df_load.write.mode("overwrite").parquet(OUTPUT_TABLA_1_DW)
    df2_load.write.mode("overwrite").parquet(OUTPUT_TABLA_2_DW)

    spark.stop()

if __name__ == "__main__":
    main()
```

Vista desde el **bash**:

```
hadoop@615cf53bef6c:~/scripts$ ls
Notebook          ingest.sh              landing_2.sh        query_db_2_hdfs_parquet.sh    spark-warehouse    transform_load.py    transform_load_4.py  transformation.py
QueryResult.java  ingest_ejercicio_1.sh  landing_3.sh        query_db_2_hdfs_parquet_2.sh  start-services.sh  transform_load_2.py  transform_load_5.py  weather_str_transform.py
derby.log         landing.sh             pyspark_jupyter.sh  query_db_2_hdfs_parquet_3.sh  tl6_run.log        transform_load_3.py  transform_load_6.py  yahoo_weather2kafka.py
hadoop@615cf53bef6c:~/scripts$ cat > transform_load_7.py
###############################################################################################################
# Archivo: transform_load_7.py
###############################################################################################################

# Importamos librerias
from pyspark.sql import SparkSession
from pyspark.sql import functions as F


def main():
    # ~~~ Parámetros de HDFS ~~~
    NN_URI = "hdfs://172.17.0.2:9000"  # ajusta si tu NameNode/puerto son otros
    INPUT_INFORME_1   = f"{NN_URI}/ingest/2021-informe-ministerio.csv"
    INPUT_INFORME_2   = f"{NN_URI}/ingest/202206-informe-ministerio.csv"
    INPUT_DETALLE_AEROPUERTOS = f"{NN_URI}/ingest/aeropuertos_detalle.csv"
    OUTPUT_TABLA_1_DW = f"{NN_URI}/tables/external/aeropuertos/aeropuerto_tabla"
    OUTPUT_TABLA_2_DW = f"{NN_URI}/tables/external/aeropuertos/aeropuerto_detalles_tabla"

    # 1) Crear la sesión de Spark con soporte Hive y FS por defecto en HDFS
    spark = (
        SparkSession
            .builder
            .appName("transform_load_7")
            .enableHiveSupport()
            .config("spark.hadoop.fs.defaultFS", NN_URI)
            .config("spark.sql.warehouse.dir", OUTPUT_TABLA_1_DW)
            .config("spark.sql.warehouse.dir", OUTPUT_TABLA_2_DW)
            .getOrCreate()
    )

    # 2) Rutas de entrada (csv desde HDFS)
    df = spark.read.csv(INPUT_INFORME_1, header=True, inferSchema=True, sep=";")
    df1 = spark.read.csv(INPUT_INFORME_2, header=True, inferSchema=True, sep=";")
    df2 = spark.read.csv(INPUT_DETALLE_AEROPUERTOS, header=True, inferSchema=True, sep=";")


    # 3) Transformaciones (casteo de tipos)

    # Casteo de df y df1 (ademas eliminamos la columna 'Calidad dato' que no es necesaria)

    def castear_vuelos(df): # Funcion para castear los dataframes de vuelos (sin 'Calidad dato')
        return df.select(
            F.to_date(F.col("Fecha"), "dd/MM/yyyy").alias("fecha"),
            F.col("Hora UTC").cast("string").alias("horaUTC"),
            F.col("Clase de Vuelo (todos los vuelos)").cast("string").alias("clase_de_vuelo"),
            F.col("Clasificación Vuelo").cast("string").alias("clasificacion_de_vuelo"),
            F.col("Tipo de Movimiento").cast("string").alias("tipo_de_movimiento"),
            F.col("Aeropuerto").cast("string").alias("aeropuerto"),
            F.col("Origen / Destino").cast("string").alias("origen_destino"),
            F.col("Aerolinea Nombre").cast("string").alias("aerolinea_nombre"),
            F.col("Aeronave").cast("string").alias("aeronave"),
            F.col("Pasajeros").cast("int").alias("pasajeros")
        )

    # Usamos la función para castear ambos dataframes

    df_cast = castear_vuelos(df)
    df1_cast = castear_vuelos(df1)
```

```
    # Usamos la función para castear ambos dataframes

    df_cast = castear_vuelos(df)
    df1_cast = castear_vuelos(df1)

    # Unimos ambos dataframes casteados

    df_union = df_cast.unionByName(df1_cast)

    # Filtramos los vuelos domésticos

    df_domestico = df_union.filter(
        F.lower(F.col("clasificacion_de_vuelo")) == "domestico"
    )

    #  Rellenamos los valores nulos en la columna 'pasajeros' con 0

    df_load = df_domestico.fillna({"pasajeros": 0})

    # Casteo de df2 (aeropuertos detalle) No figura la columna 'inhab' ni 'fir' en la tabla destino, por lo que no se incluyen

    df2_cast = df2.select(
        # local -> aeropuerto
        F.col("local").cast("string").alias("aeropuerto"),
        F.col("oaci").cast("string").alias("oac"),
        F.col("iata").cast("string").alias("iata"),
        F.col("tipo").cast("string").alias("tipo"),
        F.col("denominacion").cast("string").alias("denominacion"),
        F.col("coordenadas").cast("string").alias("coordenadas"),
        F.col("latitud").cast("string").alias("latitud"),
        F.col("longitud").cast("string").alias("longitud"),
        F.col("elev").cast("float").alias("elev"),
        F.col("uom_elev").cast("string").alias("uom_elev"),
        F.col("ref").cast("string").alias("ref"),
        F.col("distancia_ref").cast("float").alias("distancia_ref"),
        F.col("direccion_ref").cast("string").alias("direccion_ref"),
        F.col("condicion").cast("string").alias("condicion"),
        F.col("control").cast("string").alias("control"),
        F.col("region").cast("string").alias("region"),
        F.col("uso").cast("string").alias("uso"),
        F.col("trafico").cast("string").alias("trafico"),
        F.col("sna").cast("string").alias("sna"),
        F.col("concesionado").cast("string").alias("concesionado"),
        F.col("provincia").cast("string").alias("provincia"),

    )

    #  Rellenamos los valores nulos en la columna 'distancia_ref' con 0

    df2_load = df2_cast.fillna({"distancia_ref": 0})


    # (opcional) métricas rápidas al log
    print(f"[INFO] filas vuelos        : {df_load.count()}")
    print(f"[INFO] filas aeropuertos detalles : {df2_load.count()}")

    # 5) Load (Parquet a HDFS)
    df_load.write.mode("overwrite").parquet(OUTPUT_TABLA_1_DW)
    df2_load.write.mode("overwrite").parquet(OUTPUT_TABLA_2_DW)

    spark.stop()

if __name__ == "__main__":
    main()
hadoop@615cf53bef6c:~/scripts$
```

Asignamos permisos:

```
hadoop@615cf53bef6c:~/scripts$ chmod 777 transform_load_7.py
hadoop@615cf53bef6c:~/scripts$ ls -l
total 152
drwxrwxr-x 3 hadoop hadoop  4096 Sep 29 19:46 Notebook
-rw-rw-r-- 1 hadoop hadoop 14298 Nov  1 15:16 QueryResult.java
-rw-rw-r-- 1 hadoop hadoop   670 Feb 28  2022 derby.log
-rwxrwxr-x 1 hadoop hadoop   272 Sep 22 01:14 ingest.sh
-rwxrwxrwx 1 hadoop hadoop  1393 Nov 15 19:31 ingest_ejercicio_1.sh
-r-xr-xr-x 1 hadoop hadoop   398 Sep 17 16:57 landing.sh
-rwxrwxrwx 1 hadoop hadoop   716 Oct 18 16:24 landing_2.sh
-rwxrwxrwx 1 hadoop hadoop   914 Oct 24 19:25 landing_3.sh
-rwxrwxrwx 1 hadoop hadoop   273 Sep 28 12:14 pyspark_jupyter.sh
-rwxrwxrwx 1 hadoop hadoop   668 Nov  1 15:12 query_db_2_hdfs_parquet.sh
-rwxrwxrwx 1 hadoop hadoop   549 Nov  1 16:00 query_db_2_hdfs_parquet_2.sh
-rwxrwxrwx 1 hadoop hadoop   486 Nov  1 16:31 query_db_2_hdfs_parquet_3.sh
drwxr-xr-x 2 hadoop hadoop  4096 Feb  9  2022 spark-warehouse
-rwxrwxrwx 1 hadoop hadoop  1089 May  9  2022 start-services.sh
-rw-rw-r-- 1 hadoop hadoop 37302 Nov  7 13:41 tl6_run.log
-rwxrwxrwx 1 hadoop hadoop  1964 Oct 19 00:37 transform_load.py
-rwxrwxrwx 1 hadoop hadoop  2897 Oct 19 12:48 transform_load_2.py
-rwxrwxrwx 1 hadoop hadoop  3909 Oct 25 04:35 transform_load_3.py
-rwxrwxrwx 1 hadoop hadoop  1734 Nov  2 23:50 transform_load_4.py
-rwxrwxrwx 1 hadoop hadoop  2619 Nov  3 00:07 transform_load_5.py
-rwxrwxrwx 1 hadoop hadoop  2713 Nov  7 16:27 transform_load_6.py
-rwxrwxrwx 1 hadoop hadoop  5065 Nov 16 01:36 transform_load_7.py
-rwxrwxrwx 1 hadoop hadoop  1058 May  9  2022 transformation.py
-rwxrwxrwx 1 hadoop hadoop  2068 Oct 31 22:14 weather_str_transform.py
-rwxrwxrwx 1 hadoop hadoop  1747 Nov  1 01:13 yahoo_weather2kafka.py
hadoop@615cf53bef6c:~/scripts$
```

Revisamos que el script funcione correctamente:

```
hadoop@615cf53bef6c:~/scripts$ /home/hadoop/spark/bin/spark-submit --master local[*] \
>   --conf spark.sql.warehouse.dir=/user/hive/warehouse \
>   --conf spark.sql.catalogImplementation=hive \
  --files /home>   --files /home/hadoop/hive/conf/hive-site.xml \
>   /home/hadoop/scripts/transform_load_7.py 2>&1 | tee /home/hadoop/scripts/tl7_run.log
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.spark.unsafe.Platform (file:/home/hadoop/spark/jars/spark-unsafe_2.12-3.2.0.jar) to constructor java.nio.DirectByteBuffer
(long,int)
WARNING: Please consider reporting this to the maintainers of org.apache.spark.unsafe.Platform
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
WARNING: All illegal access operations will be denied in a future release
2025-11-16 01:47:18,495 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
2025-11-16 01:47:19,737 INFO spark.SparkContext: Running Spark version 3.2.0
2025-11-16 01:47:19,791 INFO resource.ResourceUtils: ==============================================================
2025-11-16 01:47:19,792 INFO resource.ResourceUtils: No custom resources configured for spark.driver.
2025-11-16 01:47:19,792 INFO resource.ResourceUtils: ==============================================================
2025-11-16 01:47:19,793 INFO spark.SparkContext: Submitted application: transform_load_7
2025-11-16 01:47:19,863 INFO resource.ResourceProfile: Default ResourceProfile created, executor resources: Map(cores -> name: cores, amount: 1, script: , vendor: , memor
y -> name: memory, amount: 1024, script: , vendor: , offHeap -> name: offHeap, amount: 0, script: , vendor: ), task resources: Map(cpus -> name: cpus, amount: 1.0)
```

```
2025-11-16 01:47:39,513 INFO datasources.FileScanRDD: Reading File path: hdfs://172.17.0.2:9000/ingest/aeropuertos_detalle.csv, range: 0-136007, partition values: [empty
row]
2025-11-16 01:47:39,531 INFO codegen.CodeGenerator: Code generated in 13.667123 ms
2025-11-16 01:47:39,541 INFO input.LineRecordReader: Found UTF-8 BOM and skipped it
2025-11-16 01:47:39,600 INFO storage.BlockManagerInfo: Removed broadcast_21_piece0 on 615cf53bef6c:33741 in memory (size: 130.1 KiB, free: 434.1 MiB)
2025-11-16 01:47:39,663 INFO output.FileOutputCommitter: Saved output of task 'attempt_202511160147396429773219028097960_0013_m_000000_49' to hdfs://172.17.0.2:9000/table
s/external/aeropuertos/aeropuerto_detalles_tabla/_temporary/0/task_202511160147396429773219028097960_0013_m_000000
2025-11-16 01:47:39,664 INFO mapred.SparkHadoopMapRedUtil: attempt_202511160147396429773219028097960_0013_m_000000_49: Committed
2025-11-16 01:47:39,665 INFO executor.Executor: Finished task 0.0 in stage 13.0 (TID 49). 2558 bytes result sent to driver
2025-11-16 01:47:39,667 INFO scheduler.TaskSetManager: Finished task 0.0 in stage 13.0 (TID 49) in 227 ms on 615cf53bef6c (executor driver) (1/1)
2025-11-16 01:47:39,667 INFO scheduler.TaskSchedulerImpl: Removed TaskSet 13.0, whose tasks have all completed, from pool
2025-11-16 01:47:39,668 INFO scheduler.DAGScheduler: ResultStage 13 (parquet at NativeMethodAccessorImpl.java:0) finished in 0.258 s
2025-11-16 01:47:39,668 INFO scheduler.DAGScheduler: Job 11 is finished. Cancelling potential speculative or zombie tasks for this job
2025-11-16 01:47:39,668 INFO scheduler.TaskSchedulerImpl: Killing all running tasks in stage 13: Stage finished
2025-11-16 01:47:39,669 INFO scheduler.DAGScheduler: Job 11 finished: parquet at NativeMethodAccessorImpl.java:0, took 0.262936 s
2025-11-16 01:47:39,670 INFO datasources.FileFormatWriter: Start to commit write Job 7729f62d-1f97-4b84-8232-b362473a585b.
2025-11-16 01:47:39,694 INFO datasources.FileFormatWriter: Write Job 7729f62d-1f97-4b84-8232-b362473a585b committed. Elapsed time: 23 ms.
2025-11-16 01:47:39,694 INFO datasources.FileFormatWriter: Finished processing stats for write job 7729f62d-1f97-4b84-8232-b362473a585b.
2025-11-16 01:47:39,710 INFO server.AbstractConnector: Stopped Spark@4709e95{HTTP/1.1, (http/1.1)}{0.0.0.0:4041}
2025-11-16 01:47:39,712 INFO ui.SparkUI: Stopped Spark web UI at http://615cf53bef6c:4041
2025-11-16 01:47:39,739 INFO spark.MapOutputTrackerMasterEndpoint: MapOutputTrackerMasterEndpoint stopped!
2025-11-16 01:47:39,769 INFO memory.MemoryStore: MemoryStore cleared
2025-11-16 01:47:39,770 INFO storage.BlockManager: BlockManager stopped
2025-11-16 01:47:39,775 INFO storage.BlockManagerMaster: BlockManagerMaster stopped
2025-11-16 01:47:39,781 INFO scheduler.OutputCommitCoordinator$OutputCommitCoordinatorEndpoint: OutputCommitCoordinator stopped!
2025-11-16 01:47:39,804 INFO spark.SparkContext: Successfully stopped SparkContext
2025-11-16 01:47:40,135 INFO util.ShutdownHookManager: Shutdown hook called
2025-11-16 01:47:40,135 INFO util.ShutdownHookManager: Deleting directory /tmp/spark-23bb4877-09e9-4349-8c7d-830996c689eb
2025-11-16 01:47:40,142 INFO util.ShutdownHookManager: Deleting directory /tmp/spark-62e33a41-ea1f-4336-b25a-a5e5db40bad6/pyspark-5bf8ea6c-aee9-4186-9793-8643f6ae2a19
2025-11-16 01:47:40,149 INFO util.ShutdownHookManager: Deleting directory /tmp/spark-62e33a41-ea1f-4336-b25a-a5e5db40bad6
hadoop@615cf53bef6c:~/scripts$
```

Procederemos con el **punto 5**, a mostrar los tipos de los campos de los dataframes obtenidos.

```
>>> df_load.printSchema()
root
 |-- fecha: date (nullable = true)
 |-- horaUTC: string (nullable = true)
 |-- clase_de_vuelo: string (nullable = true)
 |-- clasificacion_de_vuelo: string (nullable = true)
 |-- tipo_de_movimiento: string (nullable = true)
 |-- aeropuerto: string (nullable = true)
 |-- origen_destino: string (nullable = true)
 |-- aerolinea_nombre: string (nullable = true)
 |-- aeronave: string (nullable = true)
 |-- pasajeros: integer (nullable = false)
```

```
>>> df2_load.printSchema()
root
 |-- aeropuerto: string (nullable = true)
 |-- oac: string (nullable = true)
 |-- iata: string (nullable = true)
 |-- tipo: string (nullable = true)
 |-- denominacion: string (nullable = true)
 |-- coordenadas: string (nullable = true)
 |-- latitud: string (nullable = true)
 |-- longitud: string (nullable = true)
 |-- elev: float (nullable = true)
 |-- uom_elev: string (nullable = true)
 |-- ref: string (nullable = true)
 |-- distancia_ref: float (nullable = false)
 |-- direccion_ref: string (nullable = true)
 |-- condicion: string (nullable = true)
 |-- control: string (nullable = true)
 |-- region: string (nullable = true)
 |-- uso: string (nullable = true)
 |-- trafico: string (nullable = true)
 |-- sna: string (nullable = true)
 |-- concesionado: string (nullable = true)
 |-- provincia: string (nullable = true)
```

Finalmente avanzaremos en el punto 3, armaremos el piplane que realiza la transformación y carga de los datos en el warehouse.

Creamos el DAG para Airflow:

Ejercicio_1 > DAG_ejercicio_1_trabajo_final.py > ...

```
##################################################
#
# DAG creado para el ejercicio 1 Trabajo Final
# /home/hadoop/airflow/dags/DAG_ejercicio_1_trabajo_final.py
#
##################################################

# Importamos librerias

from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days_ago
from airflow.utils.task_group import TaskGroup


# Definimos los argumentos por defecto del DAG
args = {
    "owner": "airflow",
}

with DAG(
    dag_id="ingest-transform-7",
    default_args=args,
    schedule_interval="0 0 * * *",
    start_date=days_ago(1),
    catchup=False,
    dagrun_timeout=timedelta(minutes=60),
    tags=["ingest", "transform"],
) as dag:

    inicio_proceso = DummyOperator(task_id="inicio_proceso")

    finaliza_proceso = DummyOperator(task_id="finaliza_proceso")

    # Tareas Ingest - Transform - Load (sin cambios)

    with TaskGroup("ETL", tooltip="Tareas de Extracción, Transformacion y Carga de Datos") as process_group:
        products_sold = BashOperator(
            task_id='ETL_aeropuertos',
            bash_command="""
                set -e
                /home/hadoop/spark/bin/spark-submit \
                  --master local[*] \
                  --deploy-mode client \
                  --files /home/hadoop/hive/conf/hive-site.xml \
                  /home/hadoop/scripts/transform_load_7.py
            """,
        )

    # Inicio del flujo de tareas ETL
    inicio_proceso >> process_group

    # Finalizacion del proceso de tareas
    process_group >> finaliza_proceso
```

En **bash** creamos el archivo en **/home/hadoop/airflow/dags/**:

```
This message is shown once a day. To disable it please create the
/home/crbdata/.hushlogin file.
crbdata@RubenBageta:/mnt/c/Users/Carlos Rubén Bageta$ docker exec -it edvai_hadoop bash
root@615cf53bef6c:/# su hadoop
hadoop@615cf53bef6c:/$ cd /home/hadoop/airflow/dags/
hadoop@615cf53bef6c:~/airflow/dags$ cat > DAG_ejercicio_1_trabajo_final.py
#####################################################
#
# DAG creado para el ejercicio 1 Trabajo Final
# /home/hadoop/airflow/dags/DAG_ejercicio_1_trabajo_final.py
#
#####################################################

# Importamos librerias

from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days_ago
from airflow.utils.task_group import TaskGroup


# Definimos los argumentos por defecto del DAG
args = {
    "owner": "airflow",
}

with DAG(
    dag_id="ingest-transform-7",
    default_args=args,
    schedule_interval="0 0 * * *",
    start_date=days_ago(1),
    catchup=False,
    dagrun_timeout=timedelta(minutes=60),
    tags=["ingest", "transform"],
) as dag:

    inicio_proceso = DummyOperator(task_id="inicio_proceso")

    finaliza_proceso = DummyOperator(task_id="finaliza_proceso")

    # Tareas Ingest - Transform - Load (sin cambios)

    with TaskGroup("ETL", tooltip="Tareas de Extracción, Transformacion y Carga de Datos") as process_group:
        products_sold = BashOperator(
            task_id='ETL_aeropuertos',
            bash_command="""
                set -e
                /home/hadoop/spark/bin/spark-submit \
                  --master local[*] \
                  --deploy-mode client \
                  --files /home/hadoop/hive/conf/hive-site.xml \
                  /home/hadoop/scripts/transform_load_7.py
            """,
        )

    # Inicio del flujo de tareas ETL
    inicio_proceso >> process_group

    # Finalizacion del proceso de tareas
    process_group >> finaliza_proceso

hadoop@615cf53bef6c:~/airflow/dags$
```

Asignamos permisos al DAG:

```
hadoop@615cf53bef6c:~/airflow/dags$ chmod 777 DAG_ejercicio_1_trabajo_final.py
hadoop@615cf53bef6c:~/airflow/dags$ ls -l
total 40
-rwxrwxrwx 1 hadoop hadoop 1679 Nov 16 12:35 DAG_ejercicio_1_trabajo_final.py
-rw-rw-r-- 1 hadoop hadoop 1663 Oct 19 12:59 DAG_ejercicio_5.py
-rwxrwxrwx 1 hadoop hadoop 2893 Oct 25 01:49 DAG_ejercicio_5_clase_8.py
-rwxrwxrwx 1 hadoop hadoop 1742 Nov  7 15:16 DAG_ejercicio_7_clase_10.py
-rwxrwxrwx 1 hadoop hadoop 4009 Nov  2 23:53 DAG_ejercicio_7_clase_9.py
-rw-rw-r-- 1 hadoop hadoop 1496 Oct 31 21:15 DAG_str_weather.py
-rwxrwxrwx 1 hadoop hadoop  542 Nov  1 00:14 DAG_weather2kafka.py
drwxrwxrwx 2 hadoop hadoop 4096 Nov 16 12:38 __pycache__
-rw-rw-r-- 1 hadoop hadoop 1079 May  1  2022 example-DAG.py
-rw-rw-r-- 1 hadoop hadoop 1024 May  5  2022 ingest-transform.py
hadoop@615cf53bef6c:~/airflow/dags$
```

Corremos el DAG:

Verificamos ahora que se hizo correctamente el Load en las tablas correspondientes (lo hacemos desde **DBeaver**. Para esto armamos una conexión con **Hive** para leer el contenido de las tablas.

Tabla **aeropuerto_tabla**

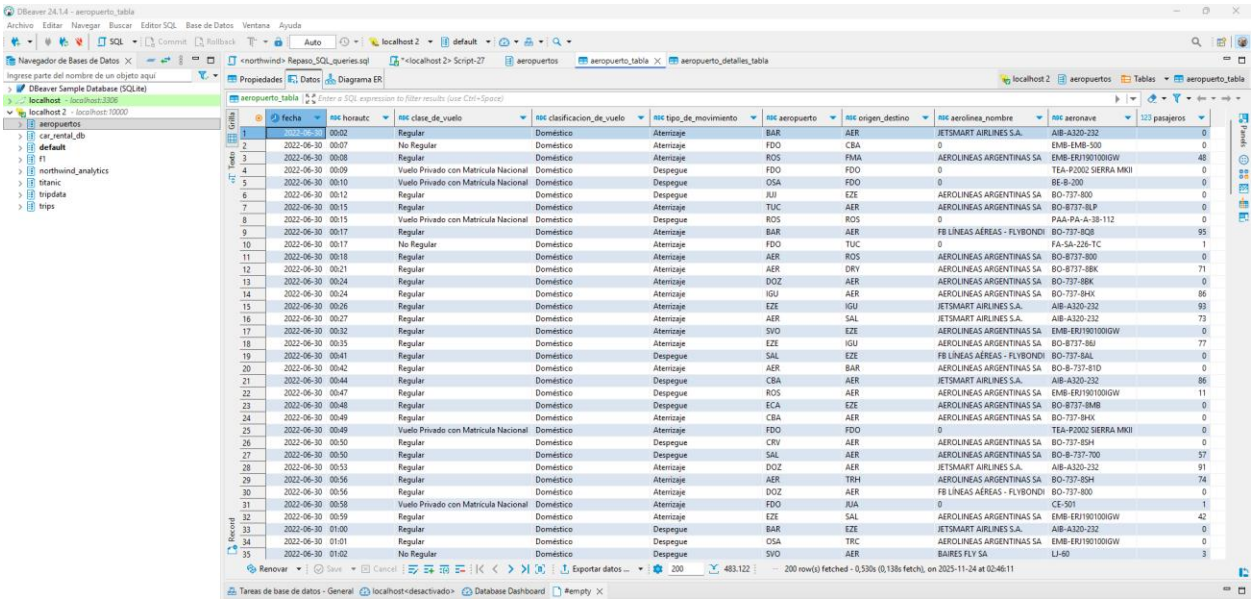

Se observa que se trajeron 483122 registros (cada uno correspondiente a un tipo de movimiento en particular: Despegue o Aterrizaje) . Estos corresponden solo a los vuelos domésticos.

La lógica de la tabla parece ser la siguiente: si el campo **tipo_de_movimiento** es *Despegue*, el campo **aeropuerto** es el de origen, y el campo **origen-destino** es el destino. Por otro lado, cuando el campo **tipo_de_movimiento** es *Aterrizaje*, el campo **aeropuerto** es el de destino y el campo **origen-destino** es el origen.

Cada registro debería ser interpretado como el correspondiente a un solo tramo de un vuelo. Puede ocurrir que el vuelo total tenga varios tramos (escalas).

Esto debería tenerse en cuenta al momento de filtrar los datos. Para que los campos **tipo_de_movimiento** y **aeropuerto** no dependan del **tipo_de_movimiento** deberemos filtrar en las consultas posteriores como **tipo_de_movimiento = Despegue** para no duplicar vuelos. La elección corresponde a que puede haber vuelos que despegaron en ese intervalo de tiempo y luego aterrizaron al día siguiente (fuera del intervalo).

Tabla **aeropuerto_detalles_tabla**

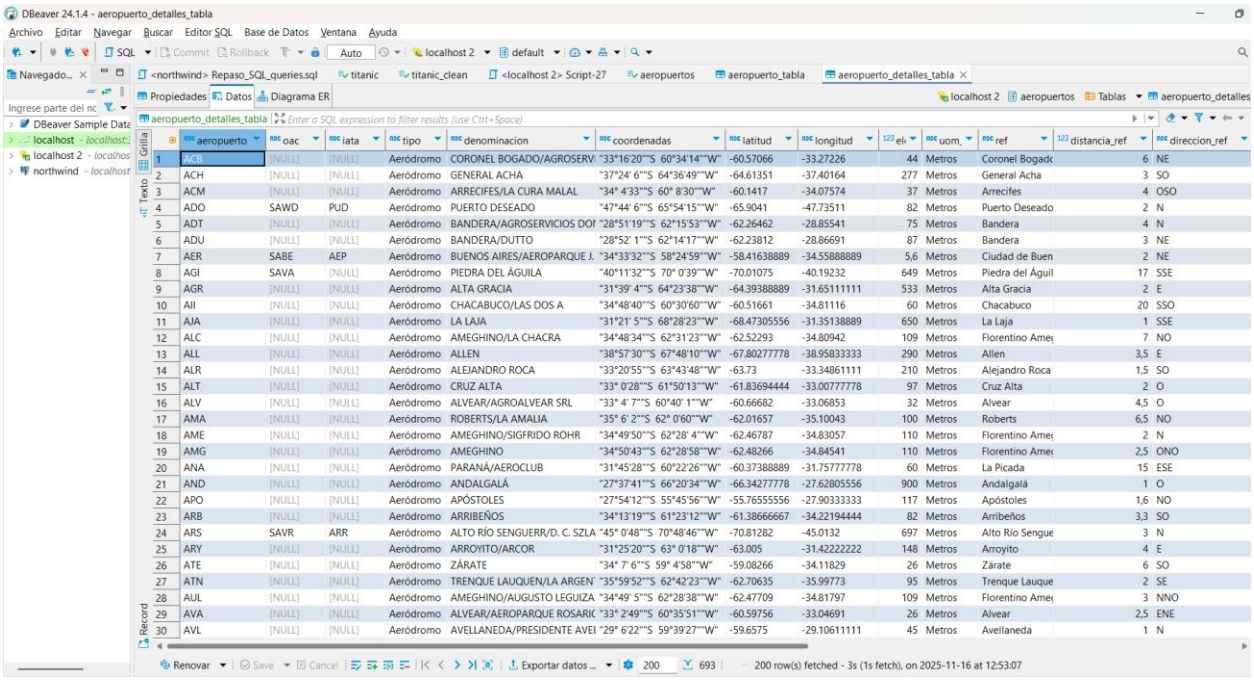

	aeropuerto	oac	iata	tipo	denominacion	coordenadas	latitud	longitud	elev	uom	ref	distancia_ref	direccion_ref
1	AGB	[NULL]	[NULL]	Aeródromo	CORONEL BOGADO/AGROSERV	"33°16'20""S 60°34'14""W"	-60.57066	-33.27226	44	Metros	Coronel Bogadc	6	NE
2	ACH	[NULL]	[NULL]	Aeródromo	GENERAL ACHA	"37°24' 6""S 64°36'49""W"	-64.61351	-37.40164	277	Metros	General Acha	3	SO
3	ACM	[NULL]	[NULL]	Aeródromo	ARRECIFES/LA CURA MALAL	"34° 4'33""S 60° 8'30""W"	-60.1417	-34.07574	37	Metros	Arrecifes	4	OSO
4	ADO	SAWD	PUD	Aeródromo	PUERTO DESEADO	"47°44' 6""S 65°54'15""W"	-65.9041	-47.73511	82	Metros	Puerto Deseado	2	N
5	ADT	[NULL]	[NULL]	Aeródromo	BANDERA/AGROSERVICIOS DO	"28°51'19""S 62°15'53""W"	-62.26462	-28.85541	75	Metros	Bandera	4	N
6	ADU	[NULL]	[NULL]	Aeródromo	BANDERA/DUTTO	"28°52' 1""S 62°14'17""W"	-62.23812	-28.86691	87	Metros	Bandera	3	NE
7	AER	SABE	AEP	Aeródromo	BUENOS AIRES/AEROPARQUE J.	"34°33'32""S 58°24'59""W"	-58.41638889	-34.55888889	5,6	Metros	Ciudad de Buen	2	NE
8	AGI	SAVA	[NULL]	Aeródromo	PIEDRA DEL ÁGUILA	"40°11'32""S 70° 0'39""W"	-70.01075	-40.19232	649	Metros	Piedra del Águil	17	SSE
9	AGR	[NULL]	[NULL]	Aeródromo	ALTA GRACIA	"31°39' 4""S 64°23'38""W"	-64.39388889	-31.65111111	533	Metros	Alta Gracia	2	E
10	AII	[NULL]	[NULL]	Aeródromo	CHACABUCO/LAS DOS A	"34°48'40""S 60°30'60""W"	-60.51661	-34.81116	60	Metros	Chacabuco	20	SSO
11	AJA	[NULL]	[NULL]	Aeródromo	LA LAJA	"31°21' 5""S 68°28'23""W"	-68.47305556	-31.35138889	650	Metros	La Laja	1	SSE
12	ALC	[NULL]	[NULL]	Aeródromo	AMEGHINO/LA CHACRA	"34°48'34""S 62°31'23""W"	-62.52293	-34.80942	109	Metros	Florentino Ame	7	NO
13	ALL	[NULL]	[NULL]	Aeródromo	ALLEN	"38°57'30""S 67°48'10""W"	-67.80277778	-38.95833333	290	Metros	Allen	3,5	E
14	ALR	[NULL]	[NULL]	Aeródromo	ALEJANDRO ROCA	"33°20'55""S 63°43'48""W"	-63.73	-33.34861111	210	Metros	Alejandro Roca	1,5	SO
15	ALT	[NULL]	[NULL]	Aeródromo	CRUZ ALTA	"33° 0'28""S 61°50'13""W"	-61.83694444	-33.00777778	97	Metros	Cruz Alta	2	O
16	ALV	[NULL]	[NULL]	Aeródromo	ALVEAR/AGROALVEAR SRL	"33° 4' 7""S 60°40' 1""W"	-60.66682	-33.06853	32	Metros	Alvear	4,5	O
17	AMA	[NULL]	[NULL]	Aeródromo	ROBERTS/LA AMALIA	"35° 6' 2""S 62° 0'60""W"	-62.01657	-35.10043	100	Metros	Roberts	6,5	NO
18	AME	[NULL]	[NULL]	Aeródromo	AMEGHINO/SIGFRIDO ROHR	"34°49'50""S 62°28' 4""W"	-62.46787	-34.83057	110	Metros	Florentino Ame	2	N
19	AMG	[NULL]	[NULL]	Aeródromo	AMEGHINO	"34°50'43""S 62°28'58""W"	-62.48266	-34.84541	110	Metros	Florentino Ame	2,5	ONO
20	ANA	[NULL]	[NULL]	Aeródromo	PARANÁ/AEROCLUB	"31°45'28""S 60°22'26""W"	-60.37388889	-31.75777778	60	Metros	La Picada	15	ESE
21	AND	[NULL]	[NULL]	Aeródromo	ANDALGALÁ	"27°37'41""S 66°20'34""W"	-66.34277778	-27.62805556	900	Metros	Andalgalá	1	O
22	APO	[NULL]	[NULL]	Aeródromo	APÓSTOLES	"27°54'12""S 55°45'56""W"	-55.76555556	-27.90333333	117	Metros	Apóstoles	1,6	NO
23	ARB	[NULL]	[NULL]	Aeródromo	ARRIBEÑOS	"34°13'19""S 61°23'12""W"	-61.38666667	-34.22194444	82	Metros	Arribeños	3,3	SO
24	ARS	SAVR	ARR	Aeródromo	ALTO RÍO SENGUERR/D. C. SZLA	"45° 0'48""S 70°48'46""W"	-70.81282	-45.0132	697	Metros	Alto Río Sengue	3	N
25	ARY	[NULL]	[NULL]	Aeródromo	ARROYITO/ARCOR	"31°25'20""S 63° 0'18""W"	-63.005	-31.42222222	148	Metros	Arroyito	4	E
26	ATE	[NULL]	[NULL]	Aeródromo	ZÁRATE	"34° 7' 6""S 59° 4'58""W"	-59.08266	-34.11829	26	Metros	Zárate	6	SO
27	ATN	[NULL]	[NULL]	Aeródromo	TRENQUE LAUQUEN/LA ARGEN	"35°59'52""S 62°42'23""W"	-62.70635	-35.99773	95	Metros	Trenque Lauque	2	SE
28	AUL	[NULL]	[NULL]	Aeródromo	AMEGHINO/AUGUSTO LEGUIZA	"34°49' 5""S 62°28'38""W"	-62.47709	-34.81797	109	Metros	Florentino Ame	3	NNO
29	AVA	[NULL]	[NULL]	Aeródromo	ALVEAR/AEROPARQUE ROSARIC	"33° 2'49""S 60°35'51""W"	-60.59756	-33.04691	26	Metros	Alvear	2,5	ENE
30	AVL	[NULL]	[NULL]	Aeródromo	AVELLANEDA/PRESIDENTE AVEI	"29° 6'22""S 59°39'27""W"	-59.6575	-29.10611111	45	Metros	Avellaneda	1	N

Se observa que se trajeron 693 registros. Estos corresponden a todos los aeropuertos del pais.

6. Determinar la cantidad de vuelos entre las fechas 01/12/2021 y 31/01/2022. Mostrar consulta y Resultado de la query

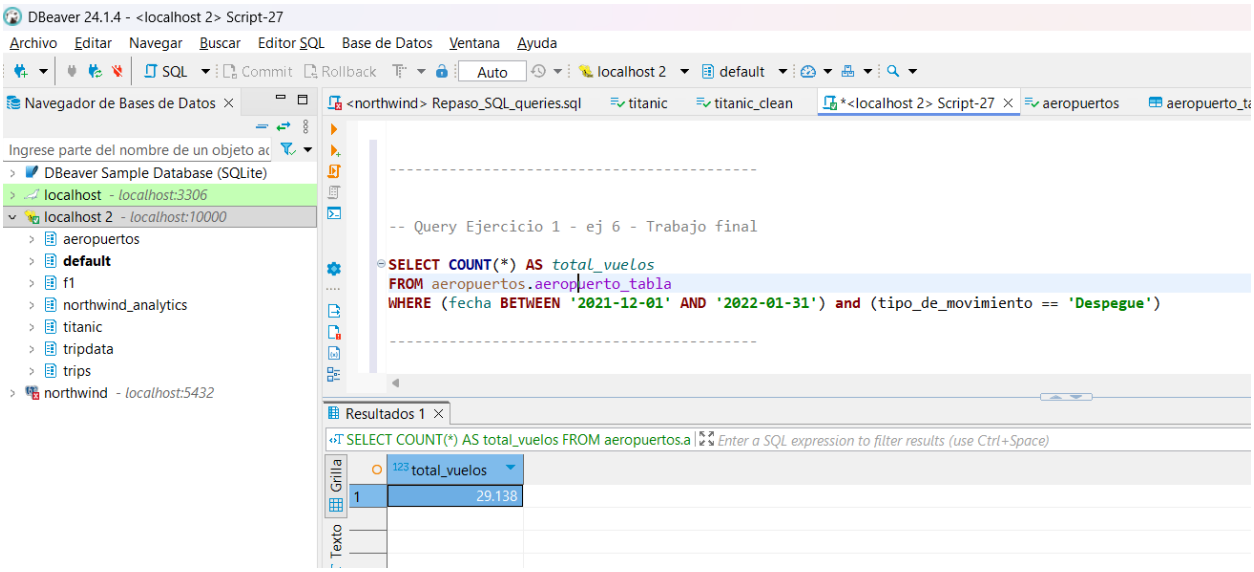

La cantidad total de vuelos domésticos que despegaron en ese intervalo de tiempo es **29138**.

7. Cantidad de pasajeros que viajaron en Aerolíneas Argentinas entre el 01/01/2021 y 30/06/2022. Mostrar consulta y Resultado de la query

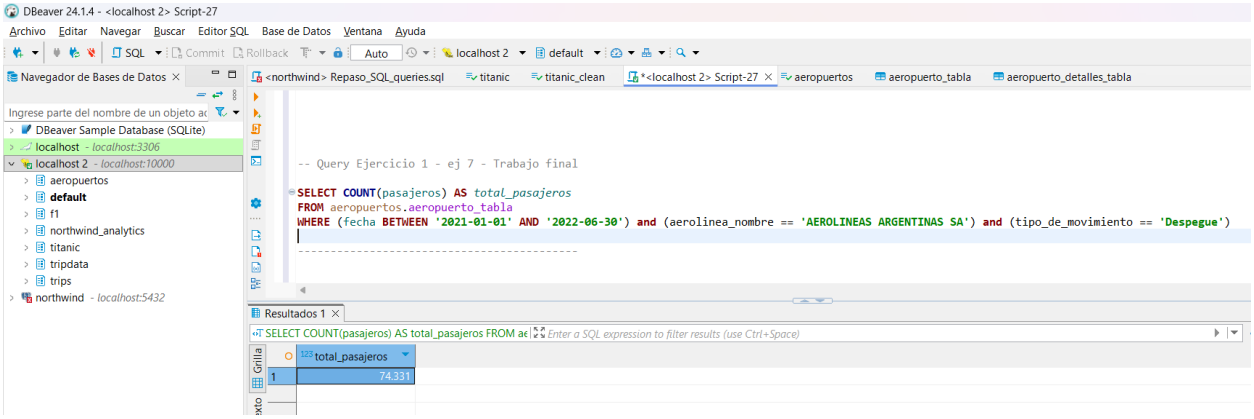

La cantidad total de pasajeros que viajaron en el lapso estipulado por Aerolíneas Argentinas fue **74331**.

8. Mostrar fecha, hora, código aeropuerto salida, ciudad de salida, código de aeropuerto de arribo, ciudad de arribo, y cantidad de pasajeros de cada vuelo, entre el 01/01/2022 y el 30/06/2022 ordenados por fecha de manera descendiente. Mostrar consulta y Resultado de la query

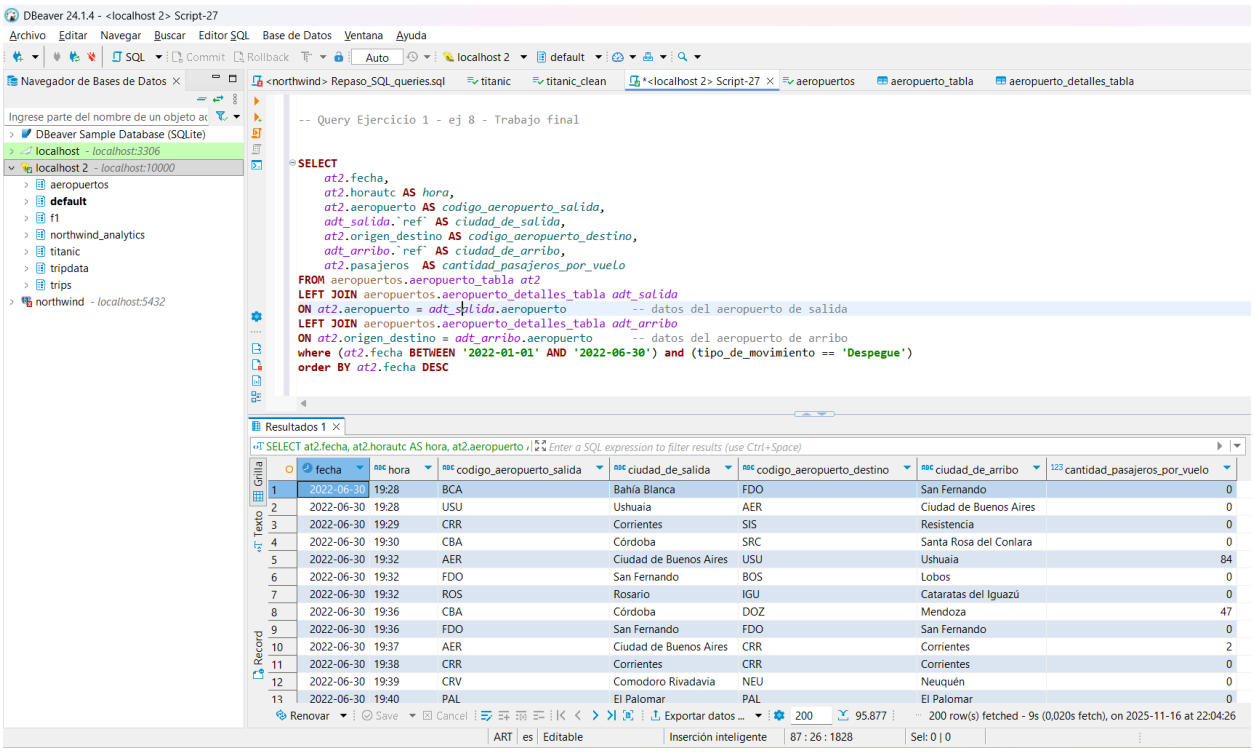

El total de registros ordenados en forma descendente en el lapso considerado es **95877.**

9. Cuales son las 10 aerolíneas que más pasajeros llevaron entre el 01/01/2021 y el 30/06/2022 exceptuando aquellas aerolíneas que no tengan nombre. Mostrar consulta y Visualización

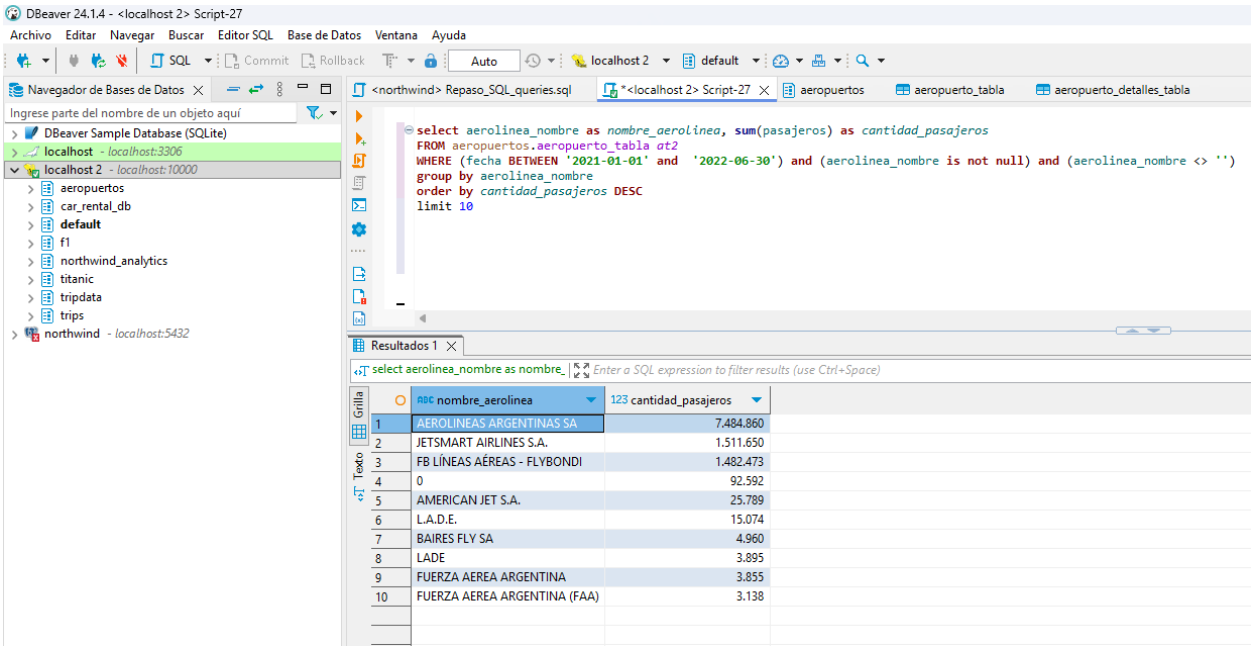

Para la visualización, se procedió a exportar la tabla generada por la consulta en DBeaver **(Tabla ejercicio 1 ej9 - Trabajo final.csv)** para luego importarla en Excel como csv.

Una vez allí, se procedió a insertar gráfico y personalizarlo:

nombre_aerolinea	cantidad_pasajeros
AEROLINEAS ARGENTINAS SA	7484860
JETSMART AIRLINES S.A.	1511650
FB LÍNEAS AÉREAS - FLYBONDI	1482473
0	92592
AMERICAN JET S.A.	25789
L.A.D.E.	15074
BAIRES FLY SA	4960
LADE	3895
FUERZA AEREA ARGENTINA	3855
FUERZA AEREA ARGENTINA (FAA)	3138

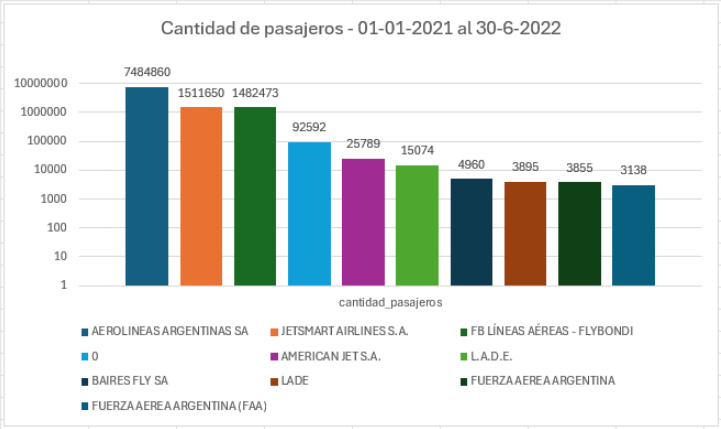

Aerolíneas Argentinas concentra cerca del 70 % del mercado de transporte aéreo de pasajeros y, en conjunto con JetSmart y Flybondi, alcanza aproximadamente el 98 % de dicho mercado.

En la visualización se utilizó escala logarítmica, dada la discrepancia en los órdenes de magnitud dentro de la variable considerada.

10. Cuales son las 10 aeronaves más utilizadas entre el 01/01/2021 y el 30/06/22 que despegaron desde la Ciudad autónoma de Buenos Aires o de Buenos Aires, exceptuando aquellas aeronaves que no cuentan con nombre. Mostrar consulta y Visualización

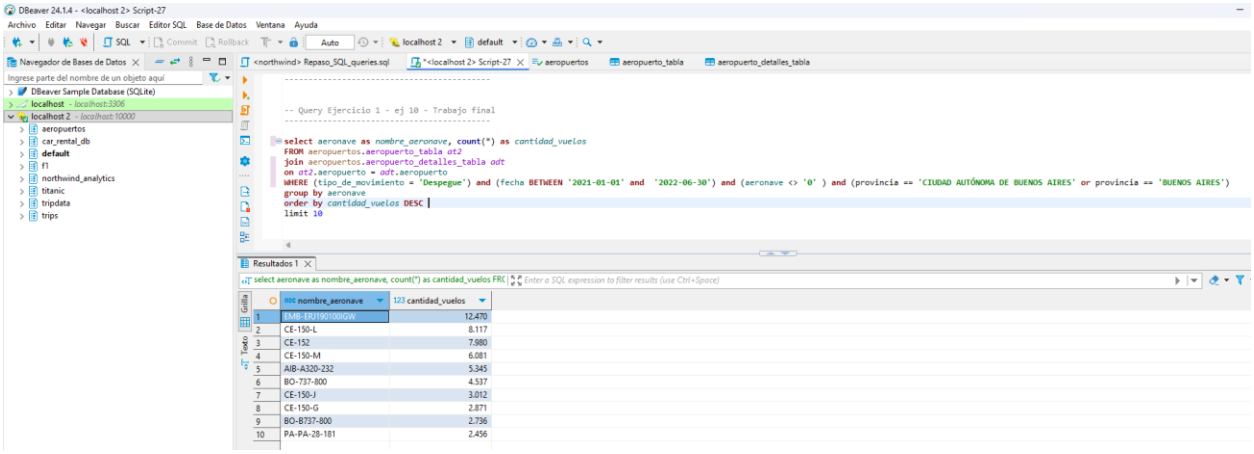

Exportamos (igual que recién) la tabla generada por la consulta en DBeaver **(Tabla ejercicio 1 ej 10 - Trabajo final.csv)** para luego importarla en Excel como csv.

nombre_aeronave	cantidad_vuelos
EMB-ERJ190100IGW	12470
CE-150-L	8117
CE-152	7980
CE-150-M	6081
AIB-A320-232	5345
BO-737-800	4537
CE-150-J	3012
CE-150-G	2871
BO-B737-800	2736
PA-PA-28-181	2456

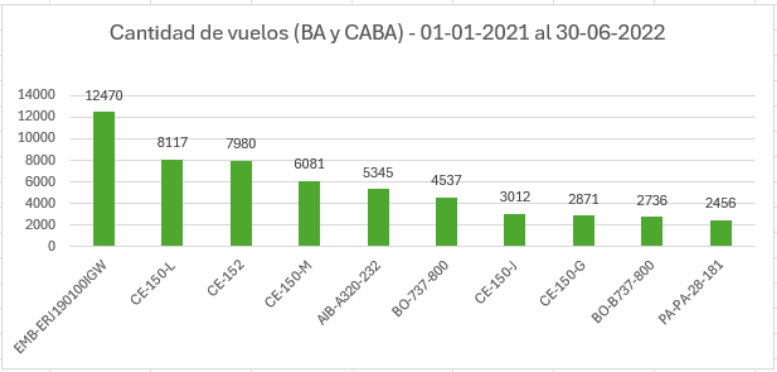

Se observa que el modelo de aeronave predominante en la cantidad de despegues de BA y CABA en el lapso considerado es **EMB – ERJ190100IGW**, con 12470 despegues.

11. Qué datos externos agregaría en este dataset que mejoraría el análisis de los datos

Considero que existen varios aspectos para mejorar el dataset:

a) En relación con la documentación de los campos, no resulta trivial determinar el significado de algunos de ellos. Por ejemplo, más arriba incorporé una discusión específica sobre la interpretación de ciertos campos, con el fin de evitar análisis erróneos derivados de la falta de documentación adecuada.
b) En términos campos a agregar, por ejemplo, ***código de vuelo***, para seguimiento; **aeropuerto_origen_codigo** y **aeropuerto_destino_codigo** separados, para facilitar el análisis y campos asociados a **fechas de salidas y llegadas programadas y reales**, para analizar demoras y congestiones.

12. Elabore sus conclusiones y recomendaciones sobre este proyecto.

Para elaborar informes más completos, resulta necesario, en primer lugar, precisar con mayor claridad las necesidades del Ministerio de Transporte y, a partir de ello, solicitar —en la medida de lo posible— acceso a información complementaria (con la que ANAC probablemente ya cuenta) sobre los vuelos en forma desagregada. Esta información permitiría enriquecer la base de datos publicada, incorporando las sugerencias indicadas en el punto 11) y otras dimensiones de análisis que pudieran surgir de los requerimientos planteados, las cuales se traducirían en nuevas variables a relevar. La construcción de KPI's (indicadores) específicos de la actividad a partir de las mismas puede generar información de valor.

Recomendaría también la implementación de una infraestructura de datos que permita un seguimiento en tiempo real de KPI's críticos del sistema que permita mejorar la toma de decisiones. De todas maneras, para datos de uso público no desestimaría la publicación de datasets mensuales (aunque mejorados).

13. Proponer una arquitectura alternativa para este proceso ya sea con herramientas on premise o cloud (Sí aplica)

Proponemos la siguiente arquitectura, basada en Google Cloud Platform (GCP):

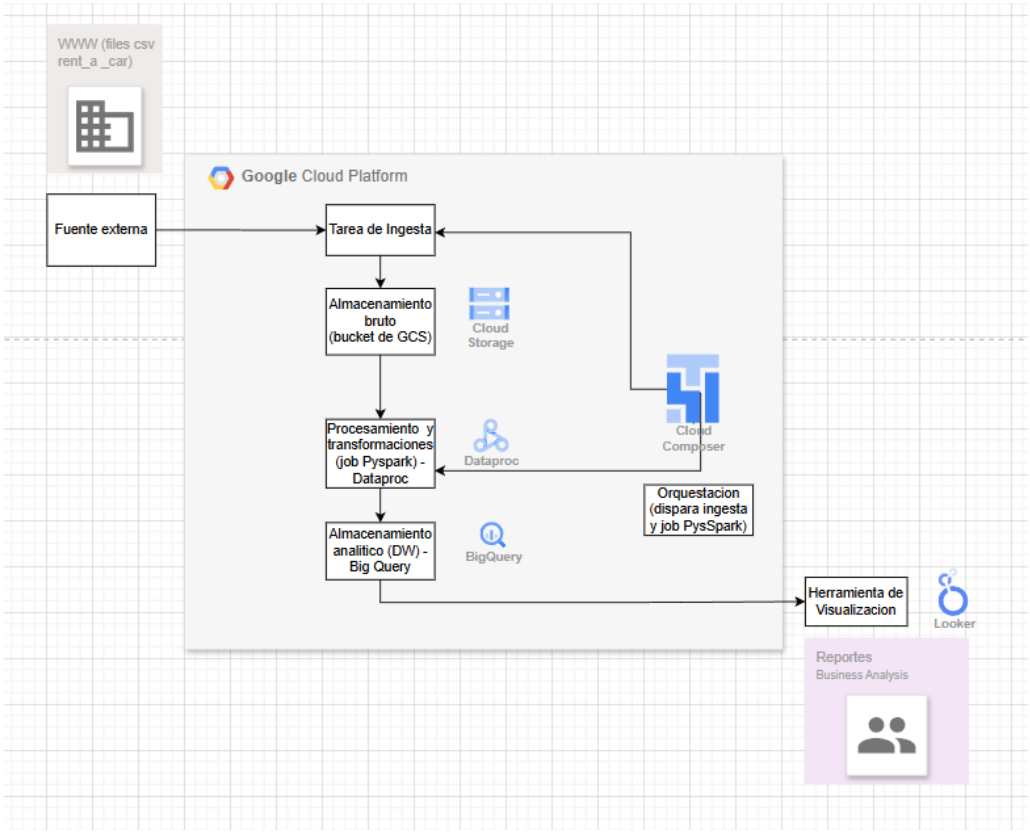

La tarea de ingesta se hace a través de un archivo similar a **ingest_ejercicio_1.sh** alojado en un bucket de Google Cloud Storage. Este proceso lo dispara Cloud Composer.

El job de PySpark (archivo similar a **transform_load_7.py**) lo ejecuta Dataproc y también es disparado por Cloud Composer.

Las tareas de consulta en SQL se realizan dentro de Big Query y finalmente, desde afuera de GCP, podemos contectarnos con alguna herramienta de visualización como Looker, para generar reportes (Dashboards).